

# 刘稔远

+86 14784206312 · renvyannnn@gmail.com · 个人主页: ryannnice.github.io · GitHub: github.com/Ryannnice

## 教育背景

香港中文大学 (深圳) (QS 18; US News 28) | 人工智能, 研究型硕士 (MPhil in AI) 2026.09 – 2028.06 (预计)  
导师: 胡君杰教授 (人工智能学院)、王阿康博士 (数据科学学院)  
广州大学 | 信息安全, 工学学士 2022.09 – 2026.07  
GPA: 89.79/100 (专业前 8%); 每年奖学金 (前 5%)、优秀毕设 (全校第三)

## 技术能力

- **LLM / Agent**: Qwen3、Transformer、CUDA; 后训练: SFT、偏好优化 (DPO/RPO)、参数高效微调 (LoRA); Embedding/Reranker、混合检索、Tool Calling、模型外记忆与 Agent 评测
- **工程 / 系统**: Python、C/C++、PyTorch、Hugging Face、MS-SWIFT、vLLM、FastAPI、Docker、Git、STM32
- **AI Coding**: 每日高强度使用 *Codex / Claude Code*, 月消耗 *Token* 百亿量级; 英语: IELTS 6.5、CET-6 564

## 项目经历

### 100 工具电商智能导购与多轮工具选链 Agent 系统 2026.07 – 至今

项目背景: 负责 100 工具、8 大业务域电商导购 Agent 研发, 解决高召回检索、多需求有序选链与跨轮指代问题。

- **意图分流 (分类准确率 100.0%)**: 构建 4.8 万条电商/闲聊数据, 对比 Qwen3-0.6B/1.7B LoRA 后选用 0.6B, 9K 测试集准确率由 84.8% 提升至 100.0%。
- **高效工具检索 (Top-10 工具全召回率 97.4%)**: 构建 7 万正对 +9.6 万类型化负例, 开展 5 种 Embedding 配方 ×3 随机种子、4 类 Reranker ×3 负例配方对照; 搜索 1,190 组一级融合参数 (去重 1,043 种排序、保留 24 组强候选) 及 38,400 条重排/候选深度/二级融合路线, 锁定向量 +BM25+RRF→Cross-encoder 的 Top-40→20→10 链路; Top-10 工具全召回率由 47.6% 提升至 97.4%, 输入 Token/重排中位延迟较 R30/P20 降低 36.8%/33.7%。
- **多步工具选链优化 (端到端准确率 92.6%)**: 完成 Qwen3-4B/8B×9K/18K/36K/54K 数据规模对照; 同风格扩量无稳定收益后, 转用 7.8 万条跨风格轨迹, 基于 MS-SWIFT/LoRA 微调 Qwen3-8B, SFT 准确率达 85.7%; 从 3.6 万条新请求中挖掘 8,309 个父模型真实错误, 分层构建 4K 偏好对; 比较 8 种 DPO/RPO 配方, 在独立 1.2K 开发集评测 28 个 checkpoint, 准确率提升至 88.9%, 端到端达 92.6%。
- **多轮 Agent (工具选择准确率 93.2%)**: 固定相同检索/Planner, 完成 12 步模块消融与 6 组参数对照: 不读历史基线为 74.6%, 直接拼接降至 69.6%, 结构化状态/滚动摘要提升至 77.0%/85.0%, 并以按需长期记忆处理远期引用; 业务操作/对话指令边界、整轮任务恢复将准确率提升至 91.2%/93.2%; 同版本计划缓存降低输入 Token 19.9%, 最终较基线准确率提升 18.6 个百分点, 错误/Token 降低 73.2%/17.8%。

## 实习经历

### 深圳市大数据研究院 (SRIBD) | 算法组实习生 2026.03 – 2026.06

#### 项目一 | 昇腾算子优化 Agent 与 DeepSeek-V4 后训练优化 2026.05 – 2026.06

项目背景: 参与深圳河套学院联合华为、智子芯元开展的 DeepSeek-V4-Pro 国产算力全参数后训练, 面向千卡昇腾 910C 上 1.6 万亿参数混合专家模型的混合稀疏注意力瓶颈, 负责算子优化 Agent 研发及融合反向算子优化。

- **算子优化 Agent (自动迭代)**: 基于 MIT Kernel Design Agents 将 NVIDIA GPU 工作流迁移至昇腾 910B/910C, 针对矩阵/向量核、片上存储与数据搬运重写规则, 打通检索 → 生成 → 编译 → 精度 → 性能 → 保留/回退闭环; 开源 Kernel-Agent-Ascend。
- **知识检索与性能诊断**: 汇总官方文档、高性能算子与 910C 实测案例, 构建覆盖分块、访存、流水同步及缓存复用的昇腾知识库; 开发兼容 CANN 7/8 的 msprof 模块, 定位计算、访存、同步等待及核间负载不均, 驱动方案迭代。
- **融合反向算子优化 (耗时降低 16.8%)**: 基于 msprof 与逐版本对照定位标量地址计算、稀疏访存和冗余同步开销; 完成整数乘除化简、低命中跨步搬运分支裁剪、无依赖流水屏障与事件同步删除; 调整注意力概率计算分块与片上缓存, 单轮处理 4→10 行、缓存 32→40 KB、循环 32→13 次, 耗时 22.603→18.81 ms。
- **精度修复与负载重平衡 (最终降低 20.9%)**: 经 V9-V13 对照定位缓存扩容引发的 64 行尾块越界, 固定 8 行向量分块; 采用向量任务重分配、GM 备用行交换、单次核间同步与缓存复用; BSND/BF16 (B=1、S=4096、K=1024) 下耗时 22.603→17.88 ms (1.26×), 四路输出余弦相似度均为 1.000000, 最大相对误差 8.39e-4。

#### 项目二 | AI Agent 应用、LLM 语义路由与昇腾推理部署 2026.03 – 2026.05

项目背景: 面向 AI 教育业务与昇腾大模型服务落地, 负责 Agent 应用开发、轻量语义路由及模型部署评测。

- **AI Agent 应用**: 从 0 开发 Web AI 教育平台及 Android 端, 落地 Agent 驱动的新闻筛选、生成与推送模块、学习模块及 Coding Agent 创作工坊。
- **轻量语义路由 (成本降低 62%)**: 参与设计基于 Query 与领域原型向量的 Domain 划分, 并结合模型内部表示判断问题难度、分配不同规模模型; 在准确率损失控制于 10% 内将推理成本降低 62%。
- **910C 推理评测**: 参与在 Ascend 910C 集群部署与测评 DeepSeek V4 Flash/Pro, 基于 ShareGPT 等数据对比 vllm\_ascend 与 SGLang, 分析 Prefill 与 Decode 阶段性能差异。

## 其它

- **学术论文**: 共 8 篇 (第一/共一 3 篇)。已录用 5 篇 (机器视觉), 含 JCR Q1 期刊 × 2、CCF-C × 1、CCF-A 中文 × 1、国际会议 Oral × 1; 在审 3 篇 (机器视觉、具身智能), 含 CCF-B × 1、JCR Q1 期刊 × 1、IEEE RA-L × 1 (语义导航)。
- **竞赛**: 亚太杯数学建模国家一等奖 (前 5%); 计算机设计大赛省一等奖 (前 3%); “大湾区杯”省一等奖、创新银奖 (第 2/1,167 队, 前 0.2%); 美赛 H 奖。
- **其它经历**: 香港大学暑校 (2026.07); 约克大学计算机学院实时分布式系统组线下暑研 (2025.06 – 2025.09; 获直博录取、国家公派全奖提名第 1; 导师: 刘鹏程教授); 香港大学暑校 (2023.11; GPA 97.5/100); 机器生命与智能研究中心科研实习 (2023.03 – 2025.12; 导师: 傅沁冰教授)。