刘稔远

+86 14784206312 · renyvannnn@gmail.com · 个人主页：ryannnice.github.io · GitHub：github.com/Ryannnice

教育背景

香港中文大学（深圳）（QS 18；US News 28）｜人工智能，研究型硕士（MPhil in AI） **2026.09 – 2028.06（预计）**
导师：李明教授（人工智能学院）；永平书院；研究方向：大语言模型 / 智能体

广州大学｜信息安全，工学学士 **2022.09 – 2026.07**
GPA：89.79/100（专业前 8%）；每年奖学金（前 5%）、优秀毕设（全校第三）

技术能力

- **LLM / Agent：**Qwen3、Transformer、CUDA；后训练：SFT、偏好优化（DPO/RPO）、参数高效微调（LoRA）；Embedding/Reranker、混合检索、Tool Calling、模型外记忆与 Agent 评测
- **工程 / 系统：**Python、C/C++、PyTorch、Hugging Face、MS-SWIFT、vLLM、FastAPI、Docker、Git、STM32
- **AI Coding：*每日高强度使用 Codex / Claude Code，月消耗 Token 百亿量级***；**英语：**IELTS 6.5、CET-6 564

项目经历

100 工具电商智能导购与多轮工具选链 Agent 系统 **2026.07 – 至今**
项目背景：负责 100 工具、8 大业务域电商导购 Agent 研发，解决高召回检索、多需求有序选链与跨轮指代问题。

- **意图分流（分类准确率 100.0%）：**构建 4.8 万条电商/闲聊数据，对比 Qwen3-0.6B/1.7B LoRA 后选用 0.6B，9K 测试集准确率由 84.8% 提升至 100.0%。
- **高效工具检索（Top-10 工具全召回率 97.4%）：**构建 7 万正对 +9.6 万类型化负例，开展 5 种 Embedding 配方 ×3 随机种子、4 类 Reranker×3 负例配方对照；搜索 1,190 组一级融合参数（去重 1,043 种排序、保留 24 组强候选）及 38,400 条重排/候选深度/二级融合路线，锁定向量 +BM25+RRF→Cross-encoder 的 Top-40→20→10 链路；Top-10 工具全召回率由 47.6% 提升至 97.4%，输入 Token/重排中位延迟较 R30/P20 降低 36.8%/33.7%。
- **多步工具选链优化（端到端准确率 92.6%）：**完成 Qwen3-4B/8B×9K/18K/36K/54K 数据规模对照；同风格扩量无稳定收益后，转用 7.8 万条跨风格轨迹，基于 MS-SWIFT/LoRA 微调 Qwen3-8B，SFT 准确率达 85.7%；从 3.6 万条新请求中挖掘 8,309 个父模型真实错误，分层构建 4K 偏好对；比较 8 种 DPO/RPO 配方，在独立 1.2K 开发集评测 28 个 checkpoint，准确率提升至 88.9%，端到端达 92.6%。
- **多轮 Agent（上下文依赖请求准确率 92.8%）：**设计模型外上下文编排器，以规则状态机调度近期状态、规则摘要与会话内 BM25，将必要历史压缩并补全为独立请求；通过请求边界与整轮恢复抑制历史污染；基于近 2,000 段 2–7 轮自然短会话完成 12 阶段消融，独立测试整体准确率较直接拼接基线 50.5%→94.6%，上下文依赖/无关请求准确率达 92.8%/97.4%，版本校验缓存使规划模型调用减少 60.3%。

实习经历

字节跳动｜火山引擎（豆包 / 火山方舟）｜实习生（深圳） **2026.09 – 至今**
工作方向：企业级 AI 智能体（ToB Agent）

深圳市大数据研究院（SRIBD）｜算法组实习生 **2026.03 – 2026.06**
导师：王阿康博士（大数据研究院、河套学院、港中深数据科学学院）；工作方向：AI Infrastructure

项目一｜昇腾算子优化 Agent 与 DeepSeek-V4 后训练优化 **2026.05 – 2026.06**
项目背景：参与深圳河套学院联合华为、智子芯元开展的 DeepSeek-V4-Pro 国产算力全参数后训练，面向千卡昇腾 910C 上 1.6 万亿参数混合专家模型的混合稀疏注意力瓶颈，负责算子优化 Agent 研发及融合反向算子优化。

- **算子优化 Agent（自动迭代）：**基于 MIT Kernel Design Agents 将 NVIDIA GPU 工作流迁移至昇腾 910B/910C，针对矩阵/向量核、片上存储与数据搬运重写规则，打通检索 → 生成 → 编译 → 精度 → 性能 → 保留/回退闭环；开源 Kernel-Agent-Ascend。
- **知识检索与性能诊断：**汇总官方文档、高性能算子与 910C 实测案例，构建覆盖分块、访存、流水同步及缓存复用的昇腾知识库；开发兼容 CANN 7/8 的 msprof 模块，定位计算、访存、同步等待及核间负载不均，驱动方案迭代。
- **融合反向算子优化（耗时降低 16.8%）：**基于 msprof 与逐版本对照定位标量地址计算、稀疏访存和冗余同步开销；完成整数乘除化简、低命中跨步搬运分支裁剪、无依赖流水屏障与事件同步删除；调整注意力概率计算分块与片上缓存，单轮处理 4→10 行、缓存 32→40 KB、循环 32→13 次，耗时 22.603→18.81 ms。
- **精度修复与负载重平衡（最终降低 20.9%）：**经 V9–V13 对照定位缓存扩容引发的 64 行尾块越界，固定 8 行向量分块；采用向量任务重分配、GM 备用行交换、单次核间同步与缓存复用；BSND/BF16（B=1、S=4096、K=1024）下耗时 22.603→17.88 ms（1.26×），四路输出余弦相似度均为 1.000000，最大相对误差 8.39e-4。

项目二｜ AI Agent 应用、LLM 语义路由与昇腾推理部署 **2026.03 – 2026.05**
项目背景：面向 AI 教育业务与昇腾大模型服务落地，负责 Agent 应用开发、轻量语义路由及模型部署评测。

- **AI Agent 应用：**从 0 开发 Web AI 教育平台及 Android 端，落地 Agent 驱动的新闻筛选、生成与推送模块、学习模块及 Coding Agent 创作工坊。
- **轻量语义路由（成本降低 62%）：**参与设计基于 Query 与领域原型向量的 Domain 划分，并结合模型内部表示判断问题难度、分配不同规模模型；在准确率损失控制于 10% 内将推理成本降低 62%。
- **910C 推理评测：**参与在 Ascend 910C 集群部署与测评 DeepSeek V4 Flash/Pro，基于 ShareGPT 等数据对比 vllm_ascend 与 SGLang，分析 Prefill 与 Decode 阶段性能差异。

其它

- **学术论文：**共 8 篇（第一/共一 3 篇）。已录用 5 篇（机器视觉），含 JCR Q1 期刊 ×2、CCF-C×1、CCF-A 中文 ×1、国际会议 Oral×1；在审 3 篇（机器视觉、具身智能），含 CCF-B×1、JCR Q1 期刊 ×1、IEEE RA-L×1（语义导航）。
- **竞赛：**亚太杯数学建模国家一等奖（前 5%）；计算机设计大赛省一等奖（前 3%）；“大湾区杯”省一等奖、创新银奖（第 2/1,167 队，前 0.2%）；美赛 H 奖。
- **其它经历：**港中深人工智能学院 RA（2026.07 – 2026.08；导师：胡君杰教授，EAR-Lab；Embodied AI）；香港大学暑校（2026.07，人工智能与机器人主题）；约克大学计算机学院 RA（2025.06 – 2025.09；Motion Planning；导师：刘鹏程教授；获直博录取，CSC 联合资助博士奖学金提名评选排名第一并获校方提名）；澳门大学跨学科项目（2023.11；GPA 97.5/100）；机器生命与智能研究中心科研实习（2023.03 – 2025.12；导师：傅沁冰教授）。